AI VIET NAM – COURSE 2023

Data Analysis - Exercise

Ngày 7 tháng 8 năm 2023

Phần I: Lý thuyết

Pandas là một thư viện trong Python với ưu điểm là nhanh, mạnh, linh động, dễ sử dụng, mã nguồn mở, công cụ dùng để phân tích và thao tác dữ liệu. Pandas được xây dựng trên thư viện NumPy và có nhiều functions hỗ trợ cleaning, analyzing, và manipulating data, có thể giúp ta extract valuable insights của các tập dữ liệu. Pandas rất hiệu quả khi sử dụng trên dữ liệu bảng, như SQL table hoặc Excel spreadsheets.

Hình 1: Logo thư viện Pandas

Một số đặc điểm của Pandas:

- Thao tác với các nguồn dữ liệu từ file csv, excel file, SQL, JSON file.
- Cung cấp các loại cấu trúc dữ liệu khác nhau như Series, DataFrame và Panel.
- Có thể đáp ứng nhiều dạng dataset khác nhau như time series, heterogeneous data, tabular và matrix data.
- Có thể làm việc với missing data bằng cách xóa chúng hoặc gán cho chúng giá trị zeros hoặc giá trị phù hợp với trạng thái test.
- Có thể dùng cho việc parsing và conversion data.
- Cung cấp các kỹ thuật lọc dữ liệu.
- Cung cấp time series functionality – date range greneration, frequency conversion, moving window statistics, data shifting và lagging.

- Tích hợp tốt với các thư viện khác của Python như Scikit-learn, statmodels và SciPy.
- Có hiệu năng cao.

Cấu trúc dữ liệu trong Pandas: Pandas được xây dựng trên NumPy array, bao gồm Series, DataFrame và Panel:

- **Series:** Có cấu trúc là mảng 1D với dữ liệu đồng nhất, loại dữ liệu có thể là integer, string, float,.. trục đánh nhãn được gọi là chỉ mục (index). Kích thước của series là không thể thay đổi (immutable) và giá trị dữ liệu có thể thay đổi (mutable). Để khởi tạo Series có thể dùng pandas.Series(data, index, dtype, copy), trong đó:
  - **data:** Nhận các giá trị có dạng ndarray, list, dictionary, constant,...
  - **index:** Giá trị index phải là duy nhất (unique), có thể hash và có kích thước bằng **data**, mặc định **index** có giá trị 0, 1, 2.
  - **dtype:** Loại dữ liệu của giá trị bên trong Series.

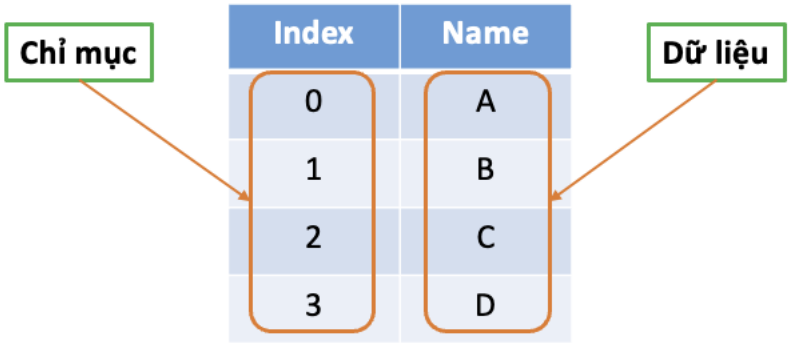

Hình 2: Ví dụ về một Series trong Pandas

- **DataFrame:** Là cấu trúc dữ liệu 2D, có dạng bảng bao gồm các cột và hàng, các cột có thể định nghĩa loại dữ liệu khác nhau. Các cột có các kiểu dữ liệu khác nhau như float64, int, bool,.. **Một cột của DataFrame là một cấu trúc Series**. Các chiều DataFrame được đánh nhãn theo các hàng và cột. Từ đó, ta có thể thao tác trên cả hàng và cột. Để khởi tạo DataFrame, có thể thực hiện bởi pandas.DataFrame(data, index, columns, dtype, copy).
  - **data:** Nhận các giá trị như ndarray, series, map, lists, dict, constants và DataFrame khác.
  - Các tham số khác tương tự như Series, pandas DataFrame có thể được tạo dùng các input như Lists, Dict, Series, Numpy ndarrays, DataFrame khác.

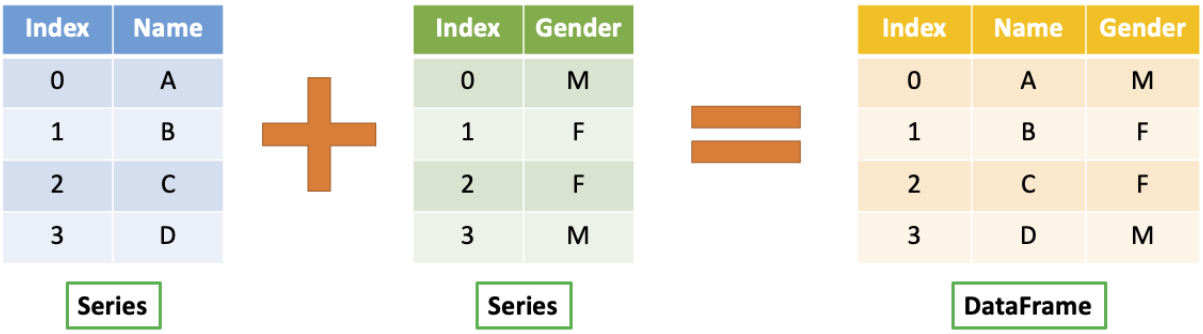

Hình 3: Ví dụ về DataFrame trong Pandas. Có thể coi DataFrame là một danh sách chứa các Series.

- **Panel:** Là một 3D container, trong đó:
  - **items:** axis 0, mỗi item tương ứng DataFrame chứa bên trong.
  - **major_axis:** axis 1, nó là các hàng (rows) của mỗi DataFrame.
  - **minor_axis:** axis 2, nó là các cột (columns) của mỗi DataFrame

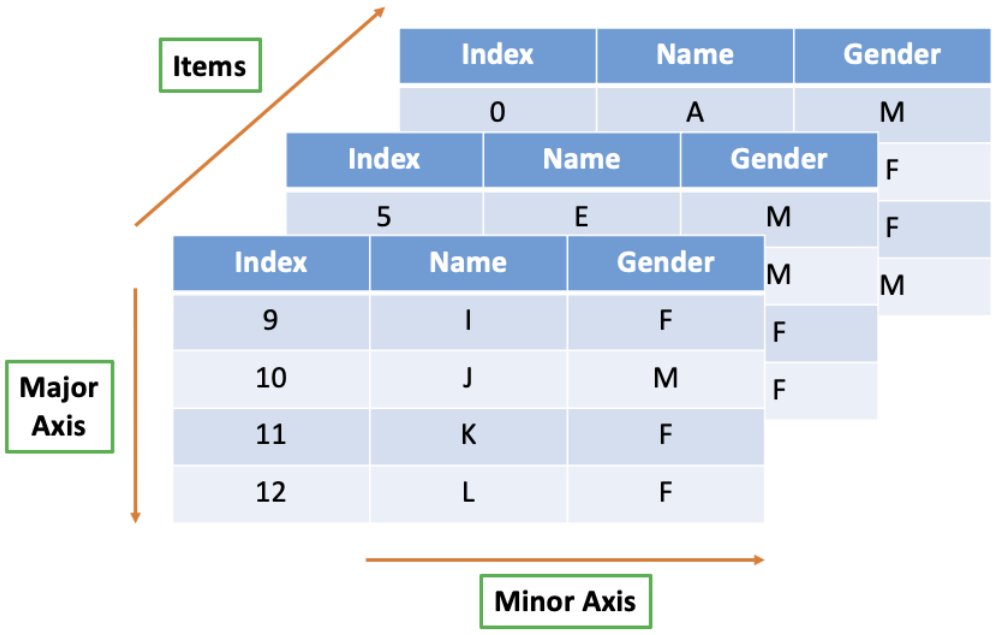

Hình 4: Ví dụ về Panel trong Pandas. Có thể coi Panel là một danh sách chứa các DataFrame.

Một số function trên Pandas thường dùng để xử lý dữ liệu:

- **Handle missing values**: isna(), notna() – tìm kiếm các giá trị NA, isnull().
- **Indexing and slicing in Pandas**: .loc (label based), .iloc (integer based), .ix (label and integer based).
- **Các query như trong excel hay SQL**: where(), query().

- **Sort**: sort_index(), sort_values().
- **Series basic functionality**: axes, dtype, empty, ndim, size, values, head(), tail().
- **Dataframe basic functionality**: T, axes, dtypes, empty, ndim, shape, size, values, head(), tail().
- **Các function liên quan thống kê**: count(), sum(), mean(), median(), model(), std(), min(), max(), abs(), prod(), cumsum(), cumprod(), describe(), ptc_change(), cov(), corr(), rank(), var(), skew(), apply().
- **Các function filter data**: groupby(), get_group(), merge(), concat(), append(), melt(), pivot(), pivot_table().
- **Một số function khác**: get_option(), set_option(), reset_option(), describe_option(), option_context().

Phần II: Bài tập

Trong phần này, chúng ta sẽ sử dụng pandas để thực hiện một số kỹ thuật phân tích trên hai bộ dữ liệu về text và time-series. Các câu bài tập được chia thành các bước thực hiện trong bài toán.

A. Data Analysis with IMDB Movie data

IMDB Movie dataset là một bộ dữ liệu đánh giá phim, dùng để phân tích mức độ quan tâm của phim theo một số tiêu chí như: đạo diễn, diễn viên, tên phim... nhằm đưa ra những góc nhìn hỗ trợ dự đoán trong tương lai. Các bạn tải bộ dữ liệu **IMDB-Movie-Data.csv** tại đây.

Các bước cần thực hiện trong bài toán:

1. Read data
2. View the data
3. Understand some basic information about the data
4. Data Selection – Indexing and Slicing data
5. Data Selection – Based on Conditional filtering
6. Groupby operations
7. Sorting operation
8. View missing values
9. Deal with missing values - Deleting
10. Deal with missing values - Filling
11. Apply() functions

Ta bắt đầu thực hiện và nhận định ở mỗi bước, code được thực hiện trên Google Colab:

1. **Import libraries và load dataset:** Để đọc một file .csv trong pandas, ta có thể dùng hàm `read_csv()` như sau:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

dataset_path = 'IMDB-Movie-Data.csv'

# Read data from .csv file
data = pd.read_csv(dataset_path)
```

Ngoài ra, ta có thể đọc đồng thời chỉ định cột làm chỉ mục cho bảng dữ liệu (mặc định pandas sẽ tự tạo một cột chỉ mục riêng). Ở đây, ta có thể chọn cột **Title** làm cột chỉ mục như sau (cột chỉ mục không được chứa giá trị trùng lặp):

```
# Read data with specified explicit index.
# We will use this later in our analysis
data_indexed = pd.read_csv(dataset_path, index_col="Title")
```

2. **View the data:** Coi qua 5 hàng đầu tiên của bảng dữ liệu bằng cách sử dụng **head()**:

```
# Preview top 5 rows using head()
data.head()
```

	Rank	Title	Genre	Description	Director	Actors	Year	Runtime (Minutes)	Rating	Votes	Revenue (Millions)	Metascore
0	1	Guardians of the Galaxy	Action,Adventure,Sci-Fi	A group of intergalactic criminals are forced ...	James Gunn	Chris Pratt, Vin Diesel, Bradley Cooper, Zoe S...	2014	121	8.1	757074	333.13	76.0
1	2	Prometheus	Adventure,Mystery,Sci-Fi	Following clues to the origin of mankind, a te...	Ridley Scott	Noomi Rapace, Logan Marshall-Green, Michael Fa...	2012	124	7.0	485820	126.46	65.0
2	3	Split	Horror,Thriller	Three girls are kidnapped by a man with a diag...	M. Night Shyamalan	James McAvoy, Anya Taylor-Joy, Haley Lu Richar...	2016	117	7.3	157606	138.12	62.0
3	4	Sing	Animation,Comedy,Family	In a city of humanoid animals, a hustling thea...	Christophe Lourdelet	Matthew McConaughey,Reese Witherspoon, Seth Ma...	2016	108	7.2	60545	270.32	59.0
4	5	Suicide Squad	Action,Adventure,Fantasy	A secret government agency recruits some of th...	David Ayer	Will Smith, Jared Leto, Margot Robbie, Viola D...	2016	123	6.2	393727	325.02	40.0

Hình 5: Một số mẫu dữ liệu đầu tiên của bộ dữ liệu

3. **Understand some basic information about the data:**

```
#Lets first understand the basic information about this data
data.info()
```

```
RangeIndex: 1000 entries, 0 to 999
Data columns (total 12 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   Rank                1000 non-null   int64
 1   Title               1000 non-null   object
 2   Genre               1000 non-null   object
 3   Description         1000 non-null   object
 4   Director            1000 non-null   object
 5   Actors              1000 non-null   object
 6   Year                1000 non-null   int64
 7   Runtime (Minutes)   1000 non-null   int64
 8   Rating              1000 non-null   float64
 9   Votes               1000 non-null   int64
 10  Revenue (Millions)  872 non-null    float64
 11  Metascore           936 non-null    float64
dtypes: float64(3), int64(4), object(5)
memory usage: 93.9+ KB
```

Hình 6: Thông tin cơ bản về bảng dữ liệu

```
data.describe()
```

	Rank	Year	Runtime (Minutes)	Rating	Votes	Revenue (Millions)	Metascore
count	1000.000000	1000.000000	1000.000000	1000.000000	1.000000e+03	872.000000	936.000000
mean	500.500000	2012.783000	113.172000	6.723200	1.698083e+05	82.956376	58.985043
std	288.819436	3.205962	18.810908	0.945429	1.887626e+05	103.253540	17.194757
min	1.000000	2006.000000	66.000000	1.900000	6.100000e+01	0.000000	11.000000
25%	250.750000	2010.000000	100.000000	6.200000	3.630900e+04	13.270000	47.000000
50%	500.500000	2014.000000	111.000000	6.800000	1.107990e+05	47.985000	59.500000
75%	750.250000	2016.000000	123.000000	7.400000	2.399098e+05	113.715000	72.000000
max	1000.000000	2016.000000	191.000000	9.000000	1.791916e+06	936.630000	100.000000

Hình 7: Tổng quan thống kê dữ liệu từ dataset

Ở đây ta có thể thấy:

- Giá trị min và max của Year, tức dataset chứa các bộ phim từ **2006** tới **2016**.
- Rating trung bình cho các bộ phim là **6.7**, thấp nhất là **1.9**, cao nhất là **9.0**.
- Doanh thu cao nhất đạt được là **936.6** triệu dollar.

4. **Data Selection – Indexing and Slicing data:** Từ bảng dữ liệu, ta có thể tách bất kì cột nào trong bảng dữ liệu để trở thành một Series hoặc một DataFrame, tùy vào phương thức tách ta sử dụng. Ở đây, ta sẽ tách một số cột trong **data** sử dụng kỹ thuật **Indexing**. Để tách cột thành Series, ta thực hiện:

```
# Extract data as series
genre = data['Genre']
genre
```

```
0       Action,Adventure,Sci-Fi
1      Adventure,Mystery,Sci-Fi
2               Horror,Thriller
3       Animation,Comedy,Family
4      Action,Adventure,Fantasy
                  ...
995         Crime,Drama,Mystery
996                      Horror
997         Drama,Music,Romance
998            Adventure,Comedy
999       Comedy,Family,Fantasy
Name: Genre, Length: 1000, dtype: object
```

Hình 8: Tách cột **Gerne** thành một Series

Để tách cột thành DataFrame, ta thực hiện:

```
# Extract data as dataframe
data[['Genre']]
```

	Genre
0	Action,Adventure,Sci-Fi
1	Adventure,Mystery,Sci-Fi
2	Horror,Thriller
3	Animation,Comedy,Family
4	Action,Adventure,Fantasy
...	...
995	Crime,Drama,Mystery
996	Horror
997	Drama,Music,Romance
998	Adventure,Comedy
999	Comedy,Family,Fantasy

1000 rows × 1 columns

Hình 9: Tách cột **Gerne** thành một DataFrame

Ta có thể chọn và tách cùng một lúc nhiều cột với nhau, tạo thành một DataFrame mới:

```
some_cols = data[['Title','Genre','Actors','Director','Rating']]
```

Đối với việc tách hàng, ta có thể tách ra một số lượng hàng nhất định, từ chỉ mục X đến chỉ mục Y trong bảng dữ liệu, gọi là **Slicing**. Ví dụ, để tách các hàng thứ 10 đến thứ 15, ta làm như sau:

```
data.iloc[10:15][['Title','Rating','Revenue (Millions)']]
```

Kết hợp với việc chọn cột, ta có một bảng dữ liệu gồm 5 mẫu dữ liệu với các trường thông tin **Title, Rating, Revenue (Millions)**.

	Title	Rating	Revenue (Millions)
10	Fantastic Beasts and Where to Find Them	7.5	234.02
11	Hidden Figures	7.8	169.27
12	Rogue One	7.9	532.17
13	Moana	7.7	248.75
14	Colossal	6.4	2.87

Hình 10: Tách một số cột tạo thành một DataFrame mới

5. **Data Selection – Based on Conditional filtering:** Ta có lấy các hàng trong bảng dữ liệu dựa trên một số điều kiện cần tuân theo. Ví dụ, ta mong muốn lấy các bộ phim từ 2010 tới 2015, với rating nhỏ hơn 6.0 nhưng lại có doanh thu thuộc top 5% trên toàn bộ dataset. Theo đó, ta có thể triển khai code như sau:

```
data[((data['Year'] >= 2010) & (data['Year'] <= 2015))
      & (data['Rating'] < 6.0)
      & (data['Revenue (Millions)'] > data['Revenue (Millions)'].quantile(0.95))]
```

	Rank	Title	Genre	Description	Director	Actors	Year	Runtime (Minutes)	Rating	Votes	Revenue (Millions)	Metascore
941	942	The Twilight Saga: Eclipse	Adventure,Drama,Fantasy	As a string of mysterious killings grips Seatt...	David Slade	Kristen Stewart, Robert Pattinson, Taylor Laut...	2010	124	4.9	192740	300.52	58.0

Hình 11: Phim với doanh thu cao trong giai đoạn năm 2010-2015

6. **Groupby Operations:** Groupby là một phép gom nhóm dữ liệu dựa trên một hoặc nhiều biến (ở đây là cột dữ liệu trong bảng). Ví dụ, ta có thể tìm số rating trung bình mà các đạo diễn đạt được bằng cách gom nhóm các chỉ số Rating của các bộ phim theo Director.

```
data.groupby('Director')[['Rating']].mean().head()
```

Director	Rating
Aamir Khan	8.5
Abdellatif Kechiche	7.8
Adam Leon	6.5
Adam McKay	7.0
Adam Shankman	6.3

Hình 12: Sử dụng groupby để tìm số rating trung bình đạt được của các đạo diễn trong bộ dữ liệu.

7. **Sorting Operations:** Sorting cho phép ta sắp xếp các hàng trong bảng dữ liệu theo thứ tự tăng/giảm dần dựa theo giá trị của cột nào đó trong bảng dữ liệu. Ví dụ, dựa trên kết quả groupby phần trước, ta có thể tìm top 5 đạo diễn đạt số rating trung bình cao nhất như sau:

```
data.groupby('Director')[['Rating']].mean().sort_values(['Rating'], ascending=
    False).head()
```

Director	Rating
Nitesh Tiwari	8.80
Christopher Nolan	8.68
Olivier Nakache	8.60
Makoto Shinkai	8.60
Aamir Khan	8.50

Hình 13: 5 đạo diễn có được số Rating trung bình cao nhất.

8. **View missing values:** Các bộ dữ liệu thường sẽ xuất hiện tình trạng bị giá trị rỗng (missing value) trong một vài trường thông tin của một số mẫu dữ liệu. Khi xử lý dữ liệu, ta cần khắc phục vấn đề này. Vì vậy, việc đầu tiên ta cần kiểm tra xem vị trí bị mất mát dữ liệu theo cách sau:

```
# To check null values row-wise
data.isnull().sum()
```

```
Rank                   0
Title                  0
Genre                  0
Description            0
Director               0
Actors                 0
Year                   0
Runtime (Minutes)      0
Rating                 0
Votes                  0
Revenue (Millions)    128
Metascore              64
dtype: int64
```

Hình 14: Bảng tổng sắp số lượng các giá trị null có trong từng cột của bảng dữ liệu

Ở đây ta thấy Revenue (Millions) và Metascore là 2 cột có chứa dữ liệu null. Để xử lý vấn đề mất mát dữ liệu, có hai phương án chính: hoặc thế các vùng trống bằng một giá trị nào đó hoặc loại bỏ chúng.

9. **Deal with missing values - Deleting** Đối với phương án loại bỏ, ta có thể loại bỏ toàn bộ cột chứa nhiều giá trị null (nếu có thể) hoặc chỉ loại bỏ các hàng chứa giá trị null. Đối với xóa cột, ta thực hiện:

```
# Use drop function to drop columns
data.drop('Metascore', axis=1).head()
```

Lệnh trên vẫn chưa drop data thực trên server cho tới khi ta thêm **inplace=True**.

	Rank	Title	Genre	Description	Director	Actors	Year	Runtime (Minutes)	Rating	Votes	Revenue (Millions)
0	1	Guardians of the Galaxy	Action,Adventure,Sci-Fi	A group of intergalactic criminals are forced ...	James Gunn	Chris Pratt, Vin Diesel, Bradley Cooper, Zoe S...	2014	121	8.1	757074	333.13
1	2	Prometheus	Adventure,Mystery,Sci-Fi	Following clues to the origin of mankind, a te...	Ridley Scott	Noomi Rapace, Logan Marshall-Green, Michael Fa...	2012	124	7.0	485820	126.46
2	3	Split	Horror,Thriller	Three girls are kidnapped by a man with a diag...	M. Night Shyamalan	James McAvoy, Anya Taylor-Joy, Haley Lu Richar...	2016	117	7.3	157606	138.12
3	4	Sing	Animation,Comedy,Family	In a city of humanoid animals, a hustling thea...	Christophe Lourdelet	Matthew McConaughey,Reese Witherspoon, Seth Ma...	2016	108	7.2	60545	270.32
4	5	Suicide Squad	Action,Adventure,Fantasy	A secret government agency recruits some of th...	David Ayer	Will Smith, Jared Leto, Margot Robbie, Viola D...	2016	123	6.2	393727	325.02

Hình 15: Bảng dữ liệu sau khi được bỏ đi cột **Metascore**

Đối với xóa hàng, ta dùng:

```
data.dropna()
```

10. **Dealing with missing values - Filling:** Đối với phương án thế giá trị mới vào các ô trống, ta có thể sử dụng các giá trị mean, median... của cột dữ liệu tương ứng để thay thế (việc chọn giá trị để thay thế còn tùy thuộc vào tính chất của bộ dữ liệu, bài toán đang giải quyết...). Ví dụ, có một vài hàng có Revenue mang giá trị null, ta có thể gán cho nó giá trị trung bình như sau:

```
revenue_mean = data_indexed['Revenue (Millions)'].mean()
print("The mean revenue is: ", revenue_mean)

# We can fill the null values with this mean revenue
data_indexed['Revenue (Millions)'].fillna(revenue_mean, inplace=True)
```

11. **apply() functions:** Apply functions được dùng khi ta muốn thực thi một hàm nào đó lên các hàng trong bảng dữ liệu. Sau khi thực thi, kết quả trả về từ hàm chính là giá trị mới của hàng tương ứng. Ví dụ, ta muốn phân loại phim theo ba mức độ [**'Good', 'Average', 'Bad'**] dựa trên **Rating**, ta có thể định nghĩa một hàm để làm đều này và apply nó lên DataFrame:

```
# Classify movies based on ratings
def rating_group(rating):
    if rating >= 7.5:
        return 'Good'
    elif rating >= 6.0:
        return 'Average'
    else:
        return 'Bad'

# Lets apply this function on our movies data
# creating a new variable in the dataset to hold the rating category
data['Rating_category'] = data['Rating'].apply(rating_group)

data[['Title','Director','Rating','Rating_category']].head(5)
```

	Title	Director	Rating	Rating_category
0	Guardians of the Galaxy	James Gunn	8.1	Good
1	Prometheus	Ridley Scott	7.0	Average
2	Split	M. Night Shyamalan	7.3	Average
3	Sing	Christophe Lourdelet	7.2	Average
4	Suicide Squad	David Ayer	6.2	Average

Hình 16: DataFrame sau khi được apply hàm **rating_group()**. Kết quả trả về sau khi thực thi hàng này sẽ được đưa vào một cột mới mang tên **Rating_category**

B. Data Analysis with Time Series data

Time series data là một dạng dữ liệu với giá trị được đo lường tại những điểm khác nhau theo thời gian. Một số dữ liệu time series được phân bố theo tần suất nhất định, ví dụ như thời tiết trong 1 giờ, lượng truy cập website trong ngày, tổng doanh thu trong tháng... Dữ liệu time series cũng có thể phân bố với khoảng cách không đều, ví dụ như số lượng cuộc gọi khẩn cấp trong ngày hoặc nhật ký hệ thống.

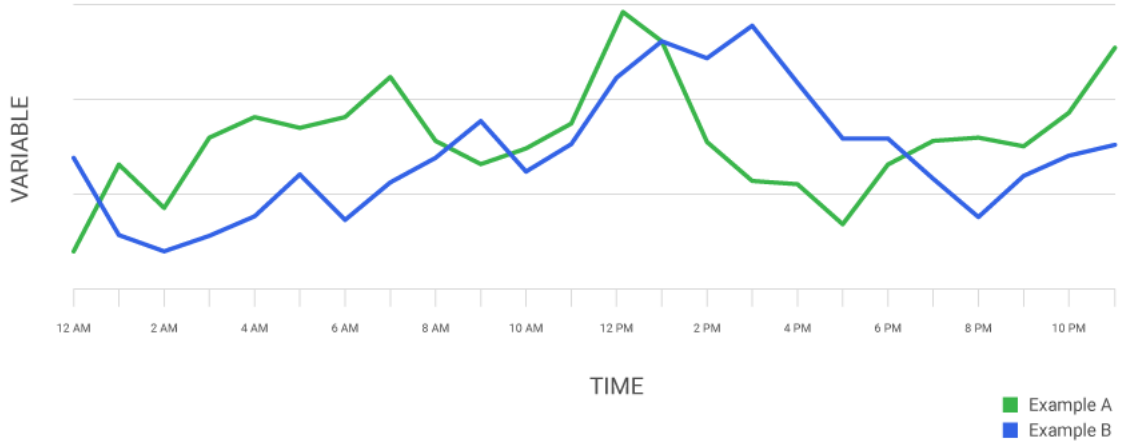

Hình 17: Hình dạng đồ thị của dữ liệu time-series

Trong phần này, chúng ta sẽ khai thác khía cạnh sắp xếp và trực quan hóa dữ liệu cho time series. Cụ thể với dữ liệu time series cho năng lượng, ta sẽ làm quen với áp dụng của các kỹ thuật time-based indexing, resampling, và rolling. Việc này sẽ giúp ta phân tích được các khía cạnh thông tin ẩn quan trọng trong dữ liệu. Ví dụ, Rolling windows có thể giúp ta khám phá các biến thể về nhu cầu điện và cung cấp năng lượng tái tạo theo thời gian. Chúng ta dùng bộ dữ liệu daily time series của Open Power System Data (OPSD) ở Đức, gồm tổng lượng tiêu thụ điện, sản xuất điện gió và sản xuất điện mặt trời trên toàn quốc trong giai đoạn 2006-2017. Các bạn tải bộ dữ liệu **opsd_germany_daily.csv** tại đây.

Chúng ta sẽ thực hiện các vấn đề sau:

- Import libraries and read dataset
- Time-based indexing
- Visualizing time series data
- Seasonality
- Frequencies
- Resampling
- Rolling windows

- Trends

Chúng ta sẽ khám phá mức tiêu thụ và sản xuất điện ở Đức thay đổi theo thời gian như thế nào, và trả lời các câu hỏi:

- Khi nào mức tiêu thụ điện thường cao nhất và thấp nhất?
- Làm thế nào để sản xuất năng lượng gió và mặt trời thay đổi theo mùa trong năm?
- Xu hướng dài hạn trong tiêu thụ điện, năng lượng mặt trời và năng lượng gió là gì?
- Làm thế nào để sản xuất năng lượng gió và mặt trời so sánh với mức tiêu thụ điện, và tỷ lệ này đã thay đổi như thế nào theo thời gian?

1. **Import libraries and read dataset:** Đầu tiên, ta vẫn dùng hàm `read_csv()` để đọc bảng dữ liệu:

```
import pandas as pd

dataset_path = './opsd_germany_daily.csv'

# Read data from .csv file
opsd_daily = pd.read_csv(dataset_path)

print(opsd_daily.shape)
print(opsd_daily.dtypes)
opsd_daily.head(3)

```

Ta được kết quả như hình bên dưới, có thể quan sát thấy nhiều giá trị bị bỏ trống ở các cột Wind, Solar, Wind+Solar:

```
(4383, 5)
Date            object
Consumption    float64
Wind           float64
Solar          float64
Wind+Solar     float64
dtype: object
```

	Date	Consumption	Wind	Solar	Wind+Solar
0	2006-01-01	1069.184	NaN	NaN	NaN
1	2006-01-02	1380.521	NaN	NaN	NaN
2	2006-01-03	1442.533	NaN	NaN	NaN

Hình 18: Một số dữ liệu đầu tiên của DataFrame

Đối với dạng dữ liệu Time Series, ta có thể chọn cột **Date** làm index (vì giá trị cột này trong bộ dữ liệu luôn là duy nhất (unique)):

```
opsd_daily = opsd_daily.set_index('Date')
opsd_daily.head(3)

```

Date	Consumption	Wind	Solar	Wind+Solar
2006-01-01	1069.184	NaN	NaN	NaN
2006-01-02	1380.521	NaN	NaN	NaN
2006-01-03	1442.533	NaN	NaN	NaN

Hình 19: Bảng dữ liệu sau khi chọn cột **Date** làm index

Ta có thể thực hiện lại bước load file và lúc này, chỉ định cột sẽ làm chỉ mục ngay từ lúc thực hiện lời gọi hàm, đồng thời tạo thêm các số cột **Year, Month, Weekday** trích từ cột **Date** để thuận tiện cho việc xử lý một số bước về sau:

```
opsd_daily = pd.read_csv('opsd_germany_daily.csv', index_col=0, parse_dates=True)

# Add columns with year, month, and weekday name
opsd_daily['Year'] = opsd_daily.index.year
opsd_daily['Month'] = opsd_daily.index.month
opsd_daily['Weekday Name'] = opsd_daily.index.day_name()
# Display a random sampling of 5 rows
opsd_daily.sample(5, random_state=0)
```

Date	Consumption	Wind	Solar	Wind+Solar	Year	Month	Weekday Name
2008-08-23	1152.011	NaN	NaN	NaN	2008	8	Saturday
2013-08-08	1291.984	79.666	93.371	173.037	2013	8	Thursday
2009-08-27	1281.057	NaN	NaN	NaN	2009	8	Thursday
2015-10-02	1391.050	81.229	160.641	241.870	2015	10	Friday
2009-06-02	1201.522	NaN	NaN	NaN	2009	6	Tuesday

Hình 20: DataFrame với các cột mới: Year, Month, Weekday

2. **Time-based indexing:** Một trong những tính năng nổi trội của pandas khi xử lý dữ liệu time series là tính năng time-based indexing, liên quan đến việc dùng dates và times để tổ chức và truy cập dữ liệu (khá giống với Indexing ở phần trước nhưng giá trị lúc này sẽ là ngày tháng năm). Việc này cho phép ta dùng loc accessor để thực thi. Ví dụ, ta có thể truy cập dữ liệu theo một khoảng thời gian từ ngày **2014-01-20** đến ngày **2014-01-22**:

```
opsd_daily.loc['2014-01-20':'2014-01-22']
```

Date	Consumption	Wind	Solar	Wind+Solar	Year	Month	Weekday Name
2014-01-20	1590.687	78.647	6.371	85.018	2014	1	Monday
2014-01-21	1624.806	15.643	5.835	21.478	2014	1	Tuesday
2014-01-22	1625.155	60.259	11.992	72.251	2014	1	Wednesday

Hình 21: Lấy các mẫu dữ liệu từ ngày 20/1/2014 đến 22/1/2014

Một tính năng khác của pandas là partial-string indexing, cho phép ta Slicing theo mô tả thời gian một cách chung chung, không cần cụ thể ngày tháng năm như ở phần trên. Ví dụ:

```
opsd_daily.loc['2012-02']
```

Date	Consumption	Wind	Solar	Wind+Solar	Year	Month	Weekday Name
2014-01-20	1590.687	78.647	6.371	85.018	2014	1	Monday
2014-01-21	1624.806	15.643	5.835	21.478	2014	1	Tuesday
2014-01-22	1625.155	60.259	11.992	72.251	2014	1	Wednesday

Hình 22: Partial-string indexing. Với việc chỉ đặt '2012-02', ta có thể lấy được toàn bộ các mẫu dữ liệu thuộc '2012-02'.

3. **Visualizing time series data:** Với việc pandas có hỗ trợ trực quan hóa dữ liệu lên đồ thị, phối hợp với thư viện seaborn ta có thể dễ dàng trực quan hóa được dữ liệu time-series lên đồ thị. Ví dụ, ta trực quan (plot) dữ liệu cột **Consumption** như sau:

```
import matplotlib.pyplot as plt
# Display figures inline in Jupyter notebook

import seaborn as sns
# Use seaborn style defaults and set the default figure size
sns.set(rc={'figure.figsize':(11, 4)})
opsd_daily['Consumption'].plot(linewidth=0.5);
```

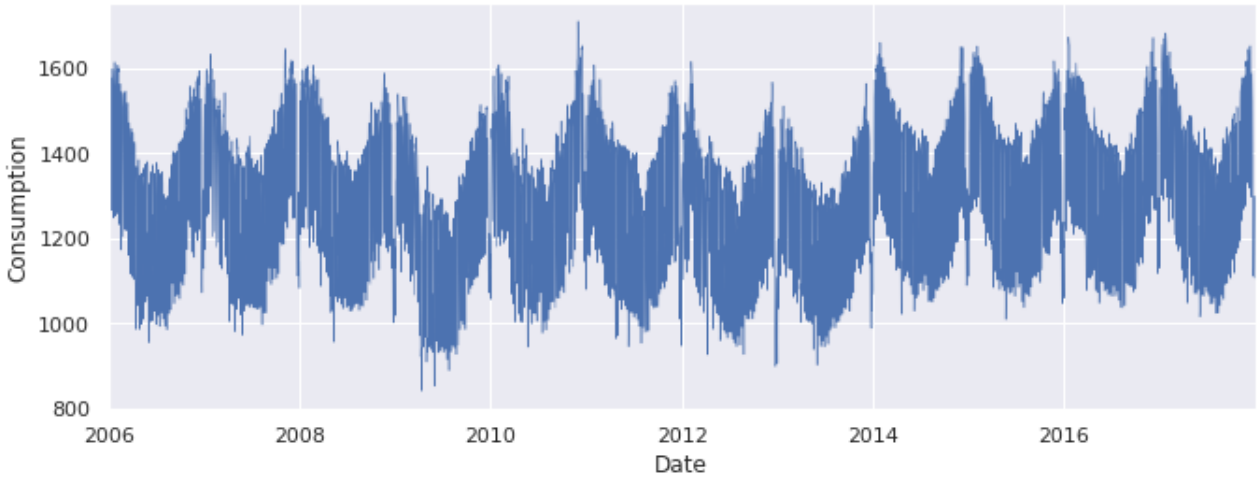

Hình 23: Đồ thị dữ liệu về mức tiêu thụ điện năng hằng ngày tại Đức

Ta có thể plot cùng lúc một số cột dữ liệu khác thành từng đồ thị riêng lẻ:

```
cols_plot = ['Consumption', 'Solar', 'Wind']
axes = opsd_daily[cols_plot].plot(marker='.', alpha=0.5, linestyle='None',
    figsize=(11, 9), subplots=True)
for ax in axes:
    ax.set_ylabel('Daily Totals (GWh)')
plt.show()
```

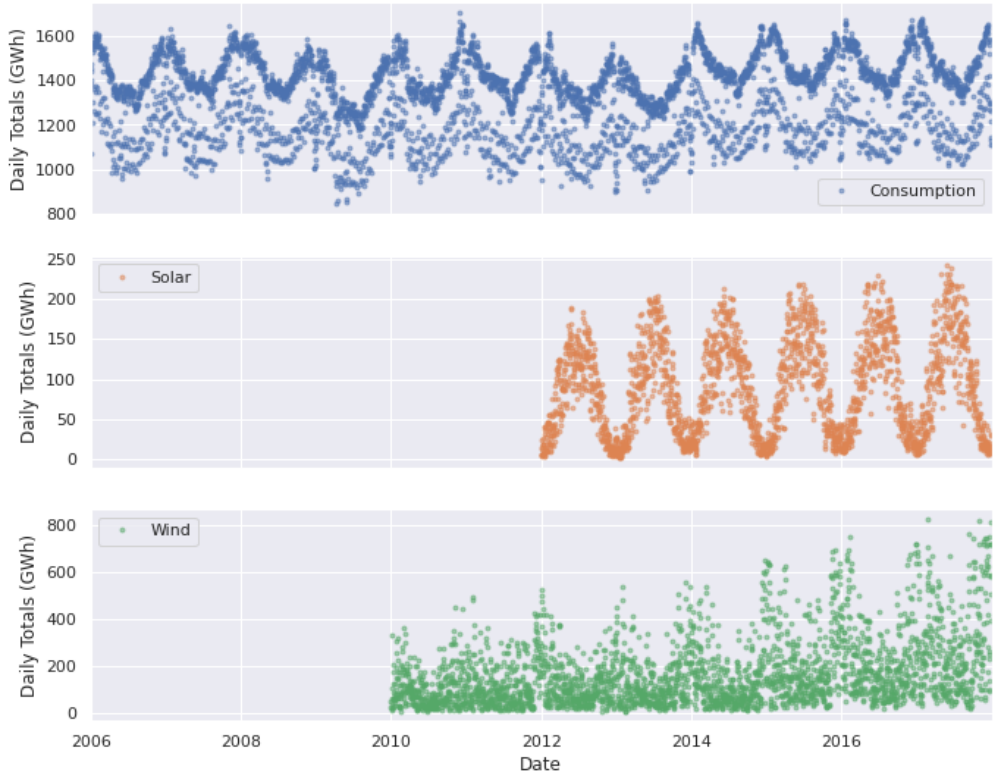

Hình 24: Đồ thị về mức tiêu thụ điện, sản lượng điện năng từ mặt trời và sản lượng điện năng từ gió

4. **Seasonality:** Tạm dịch: tính thời vụ. Chỉ số về các đặc trưng lặp đi lặp lại trong một khoảng thời gian cố định xuyên suốt các năm. Các dạng đặc trưng này thường được ảnh hưởng bởi rất nhiều yếu tố khác nhau. Ở trong dữ liệu của bài, ta có thể khai phá tính thời vụ của dữ liệu, dùng seaborn để vẽ, và group dữ liệu thành từng nhóm như sau:

```
fig, axes = plt.subplots(3, 1, figsize=(11, 10), sharex=True)
for name, ax in zip(['Consumption', 'Solar', 'Wind'], axes):
    sns.boxplot(data=opsd_daily, x='Month', y=name, ax=ax)
    ax.set_ylabel('GWh')
    ax.set_title(name)
    # Remove the automatic x-axis label from all but the bottom subplot
    if ax != axes[-1]:
        ax.set_xlabel('')
```

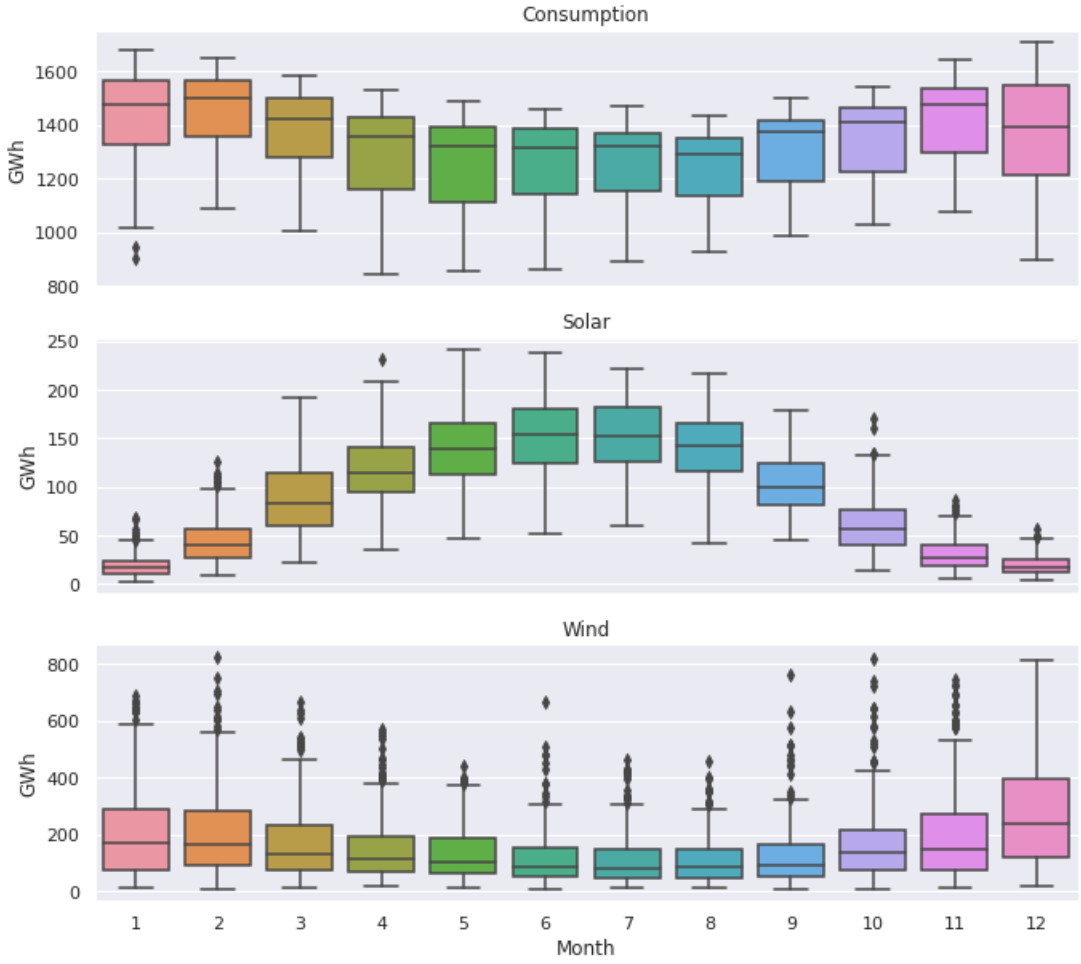

Hình 25: Biểu diễn phân bố của các cột Consumption, Wind, Solar theo Month

5. **Frequencies:** Trong DatetimeIndex của pandas, ta có thể sử dụng các giá trị thời gian sẵn có để tạo thành một chuỗi giá trị theo tần suất. Ví dụ, với hai giá trị '1998-03-10' và '1998-03-14', ta có thể tạo một danh sách thời gian với tần suất theo ngày. Tức danh sách mới của chúng ta trở thành: '1998-03-10', '1998-03-11', '1998-03-12', '1998-03-13', '1998-03-14'. Việc này được thực hiện bằng cách cài đặt thuộc tính 'freq'.

```
pd.date_range('1998-03-10', '1998-03-15', freq='D')
```

```
DatetimeIndex(['1998-03-10', '1998-03-11', '1998-03-12', '1998-03-13',
               '1998-03-14', '1998-03-15'],
              dtype='datetime64[ns]', freq='D')
```

Hình 26: Ví dụ về lấy tần suất theo ngày từ 10/3/1998 đến 15/3/1998

Với tính năng này của pandas, ta có thể thực hiện việc thế dữ liệu bị mất bằng kỹ thuật forward fill (ffill). Kỹ thuật này liên quan đến việc sử dụng giá trị ghi nhận được tại thời điểm trước đó làm giá trị thay thế cho toàn bộ giá trị bị mất mát sau đó trước khi gặp được mẫu dữ liệu có giá trị. Ví dụ, giả sử ta biết được giá trị Consumption của một vài ngày như sau:

```
# To select an arbitrary sequence of date/time values from a pandas time series,
# we need to use a DatetimeIndex, rather than simply a list of date/time strings
times_sample = pd.to_datetime(['2013-02-03', '2013-02-06', '2013-02-08'])
# Select the specified dates and just the Consumption column
consum_sample = opsd_daily.loc[times_sample, ['Consumption']].copy()
consum_sample
```

	Consumption
Date	
2013-02-03	1109.639
2013-02-06	1451.449
2013-02-08	1433.098

Hình 27: Lấy dữ liệu của 3 ngày trong bộ dữ liệu gốc làm ví dụ mẫu

```
# Convert the data to daily frequency, without filling any missings
consum_freq = consum_sample.asfreq('D')
# Create a column with missings forward filled
consum_freq['Consumption - Forward Fill'] = consum_sample.asfreq('D', method='
    ffill')
consum_freq
```

	Consumption	Consumption - Forward Fill
Date		
2013-02-03	1109.639	1109.639
2013-02-04	NaN	1109.639
2013-02-05	NaN	1109.639
2013-02-06	1451.449	1451.449
2013-02-07	NaN	1451.449
2013-02-08	1433.098	1433.098

Hình 28: Thực hiện ffill vào các ngày khác trong phạm vi từ ngày 3/2/2013 đến 8/2/2013

Với giá trị tiêu thụ điện năng của 3 ngày, ta có thể thế giá trị cho các ngày còn lại trong phạm vi của 3 ngày trên sử dụng ffill.

6. **Resampling:** Là kỹ thuật dùng để thay đổi tần số biểu diễn của bộ dữ liệu time series, có thể gia tăng hoặc giảm đi tần số lấy mẫu. Ví dụ, ta có thể giảm tần số của bộ dữ liệu hiện tại từ ngày sang tháng. Điều này đồng nghĩa với việc bộ dữ liệu mới của chúng ta sẽ có ít mẫu dữ liệu hơn bản gốc.

   Resampling thường hữu dụng với time series cho lower hoặc higher frequency. Resampling cho lower frequency (downsampling) thường liên quan tới hoạt động tổng hợp, ví dụ mức doanh thu trong tháng từ dữ liệu ngày. Resampling cho higher grequency (upsampling) ít phổ biến hơn, thường dùng trong việc nội suy. Ở đây, ta thử áp dụng downsampling cho bộ dữ liệu hiện tại như sau:

```
# Specify the data columns we want to include (i.e. exclude Year, Month, Weekday
    Name)
data_columns = ['Consumption', 'Wind', 'Solar', 'Wind+Solar']
# Resample to weekly frequency, aggregating with mean
opsd_weekly_mean = opsd_daily[data_columns].resample('W').mean()
opsd_weekly_mean.head(3)
```

   Ở đoạn code trên, ta downsampling từ tần số theo ngày sang tuần. Giá trị của các cột lúc này sẽ là trung bình của 7 ngày trong tuần.

Date	Consumption	Wind	Solar	Wind+Solar
2006-01-01	1069.184000	NaN	NaN	NaN
2006-01-08	1381.300143	NaN	NaN	NaN
2006-01-15	1486.730286	NaN	NaN	NaN

Hình 29: Sử dụng kỹ thuật Resampling để đổi tần số lấy mẫu của bộ dữ liệu từ ngày sang tuần

   Dĩ nhiên, khi ta downsampling bộ dữ liệu, số lượng mẫu dữ liệu của bảng dữ liệu mới sẽ ít hơn so với bảng gốc và ít hơn 1/7 lần. Có thể kiểm tra bằng cách dùng thuộc tính shape của DataFrame:

```
print(opsd_daily.shape[0])
print(opsd_weekly_mean.shape[0])
```

   Ta visualize daily và weekly time series của Solar trong 6 tháng như sau:

```
# Start and end of the date range to extract
start, end = '2017-01', '2017-06'
# Plot daily and weekly resampled time series together
fig, ax = plt.subplots()
ax.plot(opsd_daily.loc[start:end, 'Solar'],
marker='.', linestyle='-', linewidth=0.5, label='Daily')
ax.plot(opsd_weekly_mean.loc[start:end, 'Solar'],
marker='o', markersize=8, linestyle='-', label='Weekly Mean Resample')
ax.set_ylabel('Solar Production (GWh)')
ax.legend()
plt.show()
```

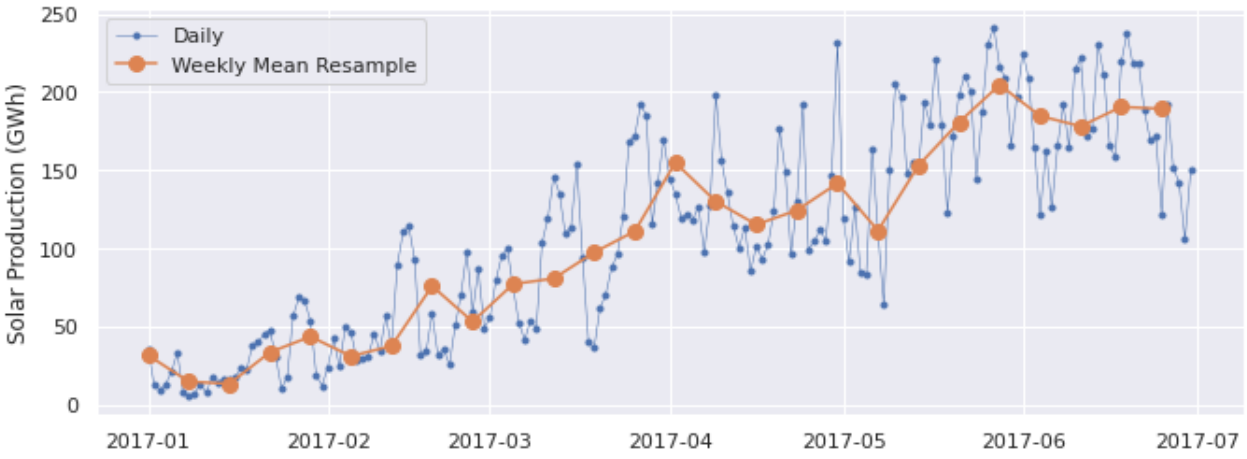

Hình 30: Đồ thị Ttme series của **Solar** theo ngày và theo tuần

Lưu ý rằng bảng dữ liệu gốc của chúng ta có tồn một số giá trị null. Vì vậy để đảm bảo toàn bộ các mẫu có giá trị, ta cài đặt tham số **min_count** vào để xử lý vấn đề này. Ví dụ, ta resampling bộ dữ liệu thành theo năm, để đảm bảo các ngày trong năm đều tồn tại giá trị non-null, ta có thể cài đặt **min_count=360** (các bạn có thể chọn **min_count** bằng một giá trị khác tùy vào quan sát cá nhân):

```
# Compute the annual sums, setting the value to NaN for any year which has
# fewer than 360 days of data
opsd_annual = opsd_daily[data_columns].resample('A').sum(min_count=360)
# The default index of the resampled DataFrame is the last day of each year,
# ('2006-12-31', '2007-12-31', etc.) so to make life easier, set the index
# to the year component
opsd_annual = opsd_annual.set_index(opsd_annual.index.year)
opsd_annual.index.name = 'Year'
# Compute the ratio of Wind+Solar to Consumption
opsd_annual['Wind+Solar/Consumption'] = opsd_annual['Wind+Solar'] / opsd_annual['
    Consumption']
opsd_annual.tail(3)
```

Year	Consumption	Wind	Solar	Wind+Solar	Wind+Solar/Consumption
2015	505264.56300	77468.994	34907.138	112376.132	0.222410
2016	505927.35400	77008.126	34562.824	111570.950	0.220528
2017	504736.36939	102667.365	35882.643	138550.008	0.274500

Hình 31: Anual resampling với bộ dữ liệu hiện tại

Ta có thể vẽ biểu đồ hiển thị sản lượng sản xuất năng lượng gió và mặt trời đóng góp vào mức độ tiêu thụ điện năng kể từ năm 2012 như sau:

```
# Plot from 2012 onwards, because there is no solar production data in earlier
    years
ax = opsd_annual.loc[2012:, 'Wind+Solar/Consumption'].plot.bar(color='C0')
```

```
ax.set_ylabel('Fraction')
ax.set_ylim(0, 0.3)
ax.set_title('Wind + Solar Share of Annual Electricity Consumption')
plt.xticks(rotation=0)
```

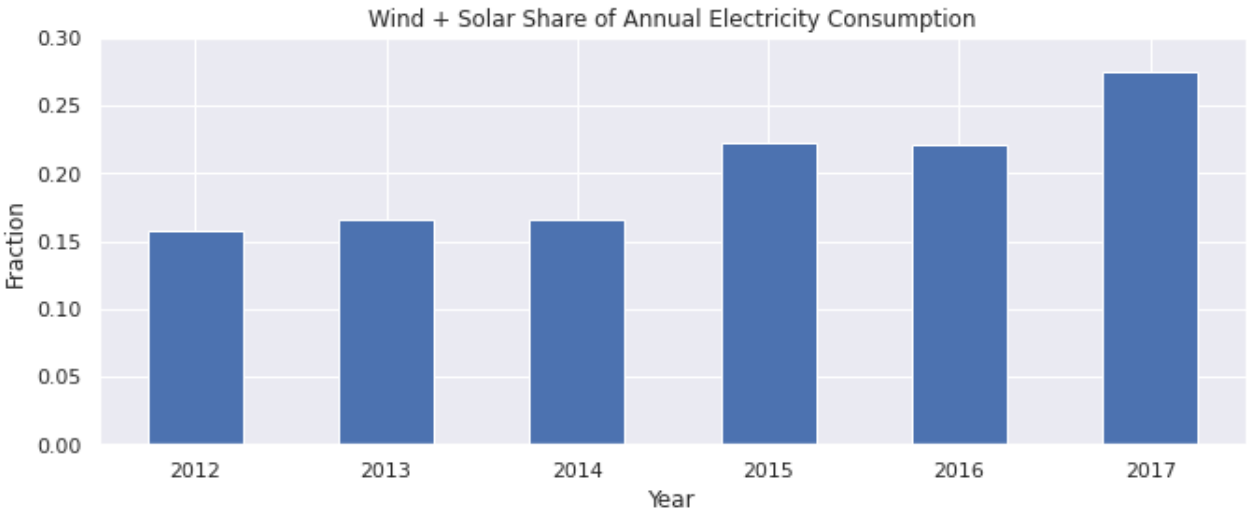

Hình 32: Biểu đồ cột biểu thị **Solar + Wind** đóng góp vào mức tiêu thụ điện năng

7. **Rolling windows:** Rolling window cũng là một hoạt động chuyển thông tin quan trọng trong dữ liệu time series. Giống downsampling, rolling windows chia dữ liệu thành các time windows (các khoảng thời gian như tuần, tháng... được trượt trên các mẫu dữ liệu theo ngày) và dữ liệu trong mỗi window đó được tổng hợp với hàm mean(), median(), sum(),... Tuy nhiên, không giống như downsampling, khi mà dữ liệu không overlap nhau và output luôn có tần số thấp hơn input, rolling windows overlap và gom thành những dữ liệu có cùng tần số, vì thế time series được chuyển có cùng tần số với time series gốc. Ta ví dụ với rolling trong 7 ngày:

```
# Compute the centered 7-day rolling mean
opsd_7d = opsd_daily[data_columns].rolling(7, center=True).mean()
opsd_7d.head(10)
```

Date	Consumption	Wind	Solar	Wind+Solar
2006-01-01	NaN	NaN	NaN	NaN
2006-01-02	NaN	NaN	NaN	NaN
2006-01-03	NaN	NaN	NaN	NaN
2006-01-04	1361.471429	NaN	NaN	NaN
2006-01-05	1381.300143	NaN	NaN	NaN
2006-01-06	1402.557571	NaN	NaN	NaN
2006-01-07	1421.754429	NaN	NaN	NaN
2006-01-08	1438.891429	NaN	NaN	NaN

Hình 33: Rolling windows với chu kỳ 7 ngày

Ở đây, 2006-01-01 đến 2006-01-07 được đánh nhãn là 2006-01-04, 2006-01-02 đến 2006-01-08 được đánh nhãn là 2006-01-05, tương tự cho các dòng khác.

8. **Trends:** Là một đặc trưng chỉ xu hướng của dữ liệu, có thể tăng hoặc giảm đi trong một khoảng thời gian dài. Với kỹ thuật rolling windows, ta có thể dễ dàng trực quan hóa trends của bộ dữ liệu, tại các time scales khác nhau. Ví dụ, ta tính 365-day rolling mean:

```
import matplotlib.dates as mdates

# The min_periods=360 argument accounts for a few isolated missing days in the
# wind and solar production time series
opsd_365d = opsd_daily[data_columns].rolling(window=365, center=True, min_periods
    =360).mean()

# Plot daily, 7-day rolling mean, and 365-day rolling mean time series
fig, ax = plt.subplots()
ax.plot(opsd_daily['Consumption'], marker='.', markersize=2, color='0.6',
linestyle='None', label='Daily')
ax.plot(opsd_7d['Consumption'], linewidth=2, label='7-d Rolling Mean')
ax.plot(opsd_365d['Consumption'], color='0.2', linewidth=3,
label='Trend (365-d Rolling Mean)')
# Set x-ticks to yearly interval and add legend and labels
ax.xaxis.set_major_locator(mdates.YearLocator())
ax.legend()
ax.set_xlabel('Year')
ax.set_ylabel('Consumption (GWh)')
ax.set_title('Trends in Electricity Consumption')
plt.show()
```

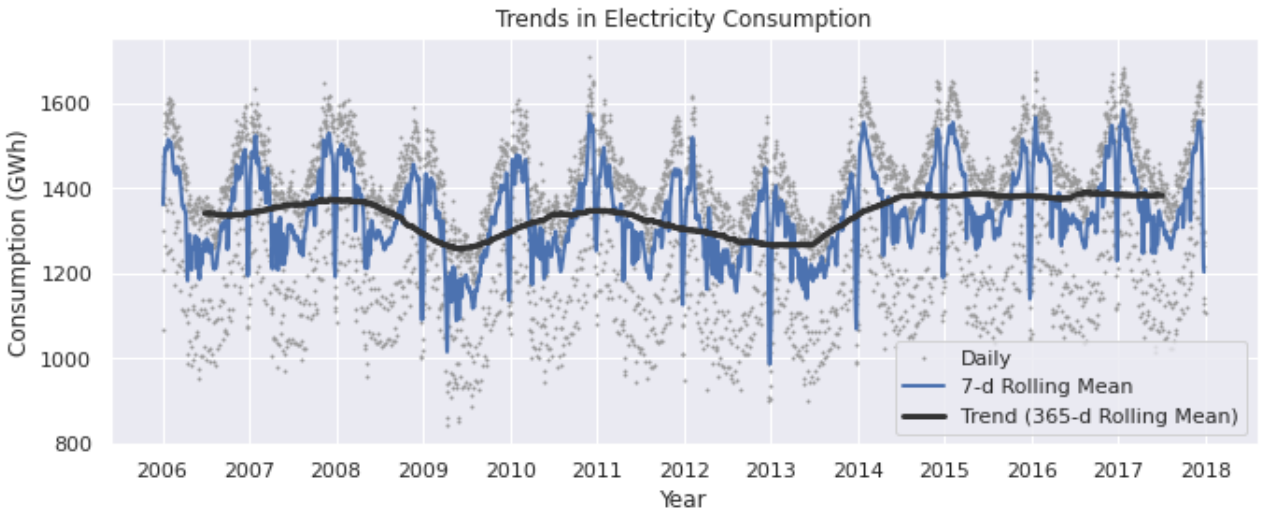

Hình 34: Xu hướng tiêu thụ điện, tuần và năm, tăng mạnh vào cuối năm

```
# Plot 365-day rolling mean time series of wind and solar power
fig, ax = plt.subplots()
for nm in ['Wind', 'Solar', 'Wind+Solar']:
    ax.plot(opsd_365d[nm], label=nm)
    # Set x-ticks to yearly interval, adjust y-axis limits, add legend and labels
    ax.xaxis.set_major_locator(mdates.YearLocator())
    ax.set_ylim(0, 400)
    ax.legend()
```

```
    ax.set_ylabel('Production (GWh)')
    ax.set_title('Trends in Electricity Production (365-d Rolling Means)')
plt.show()
```

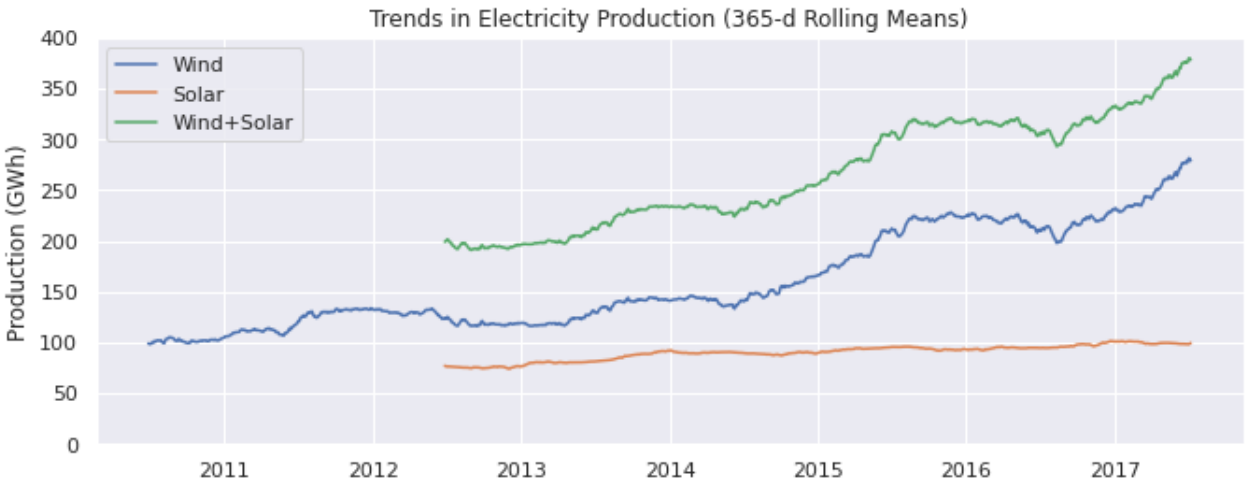

Hình 35: Xu hướng sản xuất năng lượng điện gió và mặt trời có xu hướng tăng qua hằng năm, đặc biệt là năng lượng gió

Như vậy với một số bước thực hiện trên, ta đã xem qua cách sắp xếp, phân tích và trực quan hóa dữ liệu time series data trong pandas, dùng các kỹ thuật như time-based indexing, resampling, rolling windows. Áp dụng kỹ thuật này vào bộ dataset OPSD, thu được các thông tin chi tiết về thời điểm, các kỳ, và xu hướng trong sản xuất và tiêu thụ điện.

Phần IV: Câu hỏi

A. Phần trắc nghiệm

1. Data Analysis là gì?

   (*a*) Quá trình thu thập dữ liệu.
   (*b*) Quá trình tìm kiếm và khai thác dữ liệu.
   (*c*) Quá trình xử lý dữ liệu.
   (*d*) Các phương án trên đều đúng.

2. Cấu trúc dữ liệu nào sau đây không thuộc pandas:

   (*a*) Series
   (*b*) DataFrame
   (*c*) Panel
   (*d*) Tensor

3. Ý nghĩa của phương thức head() đối với bảng dữ liệu trong pandas là:

   (*a*) Hiển thị các hàng cuối cùng
   (*b*) Hiển thị các hàng đầu tiên
   (*c*) Hiển thị ngẫu nhiên một số hàng
   (*d*) Hiển thị tất cả các hàng

4. Ý nghĩa của phương thức describe() đối với bảng dữ liệu trong pandas là:

   (*a*) Bảng thống kê của các cột dữ liệu string
   (*b*) Bảng thống kê của các cột dữ liệu số
   (*c*) Bảng thống kê của các cột dữ liệu list
   (*d*) Bảng thống kê của các cột dữ liệu dict

5. Phương thức nào sau đây được dùng để đọc một file .csv từ bộ nhớ trong pandas?

   (*a*) pd.load_csv()
   (*b*) pd.read_csv()
   (*c*) pd.read_file()
   (*d*) pd.load_file()

6. Ý nghĩa của phương thức groupby() đối với bảng dữ liệu trong pandas là:

   (*a*) Lọc các hàng theo điều kiện
   (*b*) Tổng hợp thống kê các cột dữ liệu
   (*c*) Nối các bảng dữ liệu
   (*d*) Gom nhóm dữ liệu theo giá trị của một hoặc nhiều cột

7. Phương thức nào sau đây dùng để kiểm tra các giá trị NaN có trong bảng dữ liệu?

   (*a*) df.isna()
   (*b*) df.notna()
   (*c*) df.notnull()
   (*d*) df.tail()

8. Phương thức nào sau đây có thể được dùng để bỏ đi một hàng có giá trị null trong bảng dữ liệu?

   (*a*) df.drop_null()
   (*b*) df.drop_missing()
   (*c*) df.dropna()
   (*d*) df.remove_null()

9. Phương thức nào sau đây trong pandas được dùng để fill các giá trị bị mất trong bảng dữ liệu sử dụng kỹ thuật forward filling?

(a) fillna(method='bfill')
(b) fillna(method='pad')
(c) fillna(method='ffill')
(d) fillna(method='forward')

10. Phương thức nào sau đây trong pandas được dùng để resample dữ liệu?

(a) resample()
(b) downsample()
(c) reduce()
(d) shrink()

11. Phương thức nào sau đây trong pandas được dùng để tính rolling windows?

(a) rolling()
(b) mean()
(c) average()
(d) smooth()

12. Phương thức nào sau đây trong pandas được dùng thực thi một hàm bất kì vào tất cả phần tử trong một Series?

(a) pd.Series.transform()
(b) pd.Series.applymap()
(c) pd.Series.map()
(d) pd.Series.apply()

13. Phương thức nào sau đây có thể được dùng để lấy toàn bộ một cột sử dụng tên của nó từ bảng dữ liệu?

(a) df[col]
(b) df.loc[col]
(c) df.ix[col]
(d) df.iloc[col]

14. Xem qua bảng dữ liệu sau đây (df) và trả lời các câu hỏi sau:

Date	Open	High	Low	Close	Volume	Adj Close
6/29/2010	19.000000	25.000000	17.540001	23.889999	18766300	23.889999
6/30/2010	25.790001	30.420000	23.299999	23.830000	17187100	23.830000
7/1/2010	25.000000	25.920000	20.270000	21.959999	8218800	21.959999
7/2/2010	23.000000	23.100000	18.709999	19.200001	5139800	19.200001
7/6/2010	20.000000	20.000000	15.830000	16.110001	6866900	16.110001

(a) Dòng lệnh nào sau đây dùng để chọn các hàng có giá trị 'Close' lớn hơn 25?

(a) df[df['Close'] > 25]
(b) df['Close'] > 25
(c) df.iloc[df['Close'] > 25]
(d) df[df.Close > 25]

(b) Dòng lệnh nào sau đây dùng để chọn các hàng có giá trị 'Volume' nhỏ hơn hoặc bằng 1000000?

(a) df.iloc[df['Volume'] <= 1000000]
(b) df[df['Volume'] <= 1000000]
(c) df[df.Volume <= 1000000]
(d) df['Volume'] <= 1000000

(c) Dòng lệnh nào sau đây dùng để chọn các hàng có giá trị 'High' nhỏ hơn hoặc bằng 'Low'?

(a) df.iloc[df['High'] <= df['Low']]
(b) df[df['High'] <= df['Low']]
(c) df[df.High <= df.Low]
(d) df['High'] <= df['Low']

(d) Dòng lệnh nào sau đây dùng để tìm giá trị trung bình của cột 'Close'?

(a) df.mean()
(b) df['Close'].mean
(c) df['Close'].sum()
(d) df['Close'].mean()

B. Phần nâng cao (Optional)

Cho bộ dữ liệu **GIANT: The 1-Billion Annotated Synthetic Bibliographic-Reference-String Dataset for Deep Citation Parsing** (tải tại đây), một bộ dữ liệu có kích thước rất lớn (các bạn tải tối thiểu tải 2 part đầu tiên 001 và 002). Các bạn hãy áp dụng các kỹ thuật đã đọc ở phần đầu, cũng như tìm hiểu thêm một số hướng để có đọc được bộ dữ liệu trên (gợi ý: sử dụng polars...). Sau đó, thực hiện chuẩn hóa cột '**citationStringAnnotated**' với các hàm chuẩn hóa được định nghĩa như sau:

```python
def remove_punctuations(text):
  return re.sub(r'[^\w\s]', ' ', text)

def remove_frequent(text, frequent_words):
  return ' '.join([w for w in text.split() if w not in frequent_words])

def remove_url(text):
  url_pattern = re.compile(r'https?://\S+|www\.\S+')

  return url_pattern.sub(r' ', str(text))

def remove_short_word(text, len_w=3):
  return ' '.join([w for w in text.split() if len(w) > len_w])

def remove_digits(text):
  return re.sub("^\d+\s|\s\d+\s|\s\d+$", ' ', text)

def remove_html_tag(text):
  html_pattern = re.compile(r'<.*?>')

  return html_pattern.sub(' ', str(text))

def remove_word_containing_digits(text):
  return re.sub("\S*\d\S*", " ", text)

def remove_long_word(text, len_w=25):
  return ' '.join([w for w in text.split() if len(w) < len_w])
```

Polars là một thư viện hỗ trợ thao tác với DataFrame tương tự như Paandas nhưng với tốc độ xử lý vượt trội, được viết trên nền ngôn ngữ Rust. Polars hiện vẫn đang trong giai đoạn phát triển nên vẫn còn thiếu sót nhiều tính năng, song hứa hẹn sẽ là một thư viện xử lý dữ liệu hiệu năng cao.

Hình 36: Logo của thư viện Polars

Để tiếp cận hướng sử dụng Polars, các bạn có thể làm quen với một vài thao tác cơ bản trong Polars với hướng dẫn sau. Các bạn tải bộ dữ liệu **Housing.csv** cho phần này tại đây.

1. **Import libraries and read dataset:** Đầu tiên, các bạn import thư viện polars (viết tắt là `pl`) và đọc file dữ liệu. Việc đọc dữ liệu trong polars có thể sử dụng hàm `read_csv()`, tương tự như pandas:

```
import numpy as np
import polars as pl
import matplotlib.pyplot as plt

dataset_path = 'Housing.csv'

# Read data from .csv file
data = pl.read_csv(dataset_path)
```

shape: (545, 13)

price	area	bedrooms	bathrooms	stories	mainroad	guestroom	basement	hotwaterheating	airconditioning	parking	prefarea	furnishingstatus
i64	i64	i64	i64	i64	str	str	str	str	str	i64	str	str
13300000	7420	4	2	3	"yes"	"no"	"no"	"no"	"yes"	2	"yes"	"furnished"
12250000	8960	4	4	4	"yes"	"no"	"no"	"no"	"yes"	3	"no"	"furnished"
12250000	9960	3	2	2	"yes"	"no"	"yes"	"no"	"no"	2	"yes"	"semi-furnished…
12215000	7500	4	2	2	"yes"	"no"	"yes"	"no"	"yes"	3	"yes"	"furnished"
11410000	7420	4	1	2	"yes"	"yes"	"yes"	"no"	"yes"	2	"no"	"furnished"
10850000	7500	3	3	1	"yes"	"no"	"yes"	"no"	"yes"	2	"yes"	"semi-furnished…
10150000	8580	4	3	4	"yes"	"no"	"no"	"no"	"yes"	2	"yes"	"semi-furnished…

Hình 37: Một vài mẫu dữ liệu Housing

Note: Các bạn đọc thêm về hàm `polars.read_csv()` tại đây.

2. **View dataset:** Tương tự pandas, các bạn có thể coi một vài thống kê của bộ dữ liệu như sau:

```
data.describe()
```

shape: (9, 14)

describe	price	area	bedrooms	bathrooms	stories	mainroad	guestroom	basement	hotwaterheating	airconditioning	parking	prefarea	furnishingstatus
str	f64	f64	f64	f64	f64	str	str	str	str	str	f64	str	str
"count"	545.0	545.0	545.0	545.0	545.0	"545"	"545"	"545"	"545"	"545"	545.0	"545"	"545"
"null_count"	0.0	0.0	0.0	0.0	0.0	"0"	"0"	"0"	"0"	"0"	0.0	"0"	"0"
"mean"	4.7667e6	5150.541284	2.965138	1.286239	1.805505	null	null	null	null	null	0.693578	null	null
"std"	1.8704e6	2170.141023	0.738064	0.50247	0.867492	null	null	null	null	null	0.861586	null	null
"min"	1.75e6	1650.0	1.0	1.0	1.0	"no"	"no"	"no"	"no"	"no"	0.0	"no"	"furnished"
"max"	1.33e7	16200.0	6.0	4.0	4.0	"yes"	"yes"	"yes"	"yes"	"yes"	3.0	"yes"	"unfurnished"
"median"	4.34e6	4600.0	3.0	1.0	2.0	null	null	null	null	null	0.0	null	null
"25%"	3.43e6	3600.0	2.0	1.0	1.0	null	null	null	null	null	0.0	null	null
"75%"	5.74e6	6360.0	3.0	2.0	2.0	null	null	null	null	null	1.0	null	null

Hình 38: Bảng thống kê cho bộ dữ liệu Housing

Note: Các bạn đọc thêm về hàm `polars.DataFrame.describe()` tại đây.

3. **Data Selection - Columns:** Trong polars, chúng ta có thể sử dụng các cách sau để tách dữ liệu của một cột. Ví dụ, để tách cột **price**, ta thực hiện:

```python
# price column as Series
price_col = data['price']

# price column as DataFrame
price_col = data[['price']]

# price column as DataFrame but using select() method
price_col = data.select('price')
```

Cũng tương tự như pandas, ta có thể tách nhiều cột cùng lúc:

```python
# Method 1
columns = data[['price', 'area', 'bedrooms', 'bathrooms']]

# Method 2
columns = data.select(['price', 'area', 'bedrooms', 'bathrooms'])
```

Note: Các bạn đọc thêm về hàm `polars.DataFrame.select()` tại đây.

4. **Data Selection - Rows:** Trong polars, chỉ mục được loại bỏ khi biểu diễn các bảng dữ liệu. Song, ta vẫn có thể trích các hàng theo thứ tự (tính từ vị trí thứ 0) của chúng. Ví dụ, ta trích ra 2 hàng tính từ hàng thứ 20, chỉ lấy 3 cột price, area và bedrooms:

```python
data.slice(
    20, 2
).select(
    ['price', 'area', 'bedrooms']
)
```

shape: (2, 3)

price	area	bedrooms
i64	i64	i64
8750000	4320	3
8680000	7155	3

Hình 39: Kết quả slicing

Note: Các bạn đọc thêm về hàm `polars.DataFrame.slice()` tại đây.

Ta cũng có thể tách hàng theo một số điều kiện nào đó. Ví dụ, ta có thể lấy các mẫu nhà có guestroom và không có basement, chỉ lấy thông tin cột price, area, bedrooms và stories như sau:

```python
data.filter(
    (data['guestroom'] == 'yes') &
    (data['basement'] == 'no')
)[['price', 'area', 'bedrooms', 'stories']]
```

shape: (26, 4)

price	area	bedrooms	stories
i64	i64	i64	i64
9800000	5750	3	4
8890000	4600	3	2
7962500	6000	3	4
7350000	6000	4	4
7350000	6000	3	2

Hình 40: Kết quả filter với điều kiện nêu trên

Note: Các bạn đọc thêm về hàm `polars.DataFrame.filter()` tại đây.

5. **Create new column:** Trong polars, ta có thể tạo thêm một cột mới bằng cách sau:

```
data.with_columns(
    pl.lit(0).alias('temp_column')
)
```

Ở đây, ta sử dụng hàm `with_columns()` để tạo cột mới, giá trị của cột sẽ được khởi tạo bằng giá trị 0, đặt tên là **temp_column**. Dựa theo cách triển khai này, ta cũng có thể copy một cột và đặt với một tên gọi mới như sau:

```
# Copy price column
data.with_columns(
    pl.col('price').alias('new_price')
)
```

Note: Các bạn đọc thêm về hàm `polars.DataFrame.with_columns()` tại đây.

6. **apply():** Ta có thể thực thi hàm trên một trường thông tin tương tự như pandas. Ví dụ, ta muốn đổi các giá trị "yes"/"no" trên các cột **mainroad, guestroom, basement, hotwaterheating, airconditioning, prefarea** thành giá trị 1/0 tương ứng:

```
def binary_2_numeric(decision):
    if decision == 'yes':
        return 1
    else:
        return 0

applied_data = data.with_columns(
    pl.col('mainroad').apply(binary_2_numeric),
    pl.col('guestroom').apply(binary_2_numeric),
    pl.col('basement').apply(binary_2_numeric),
    pl.col('hotwaterheating').apply(binary_2_numeric),
    pl.col('airconditioning').apply(binary_2_numeric),
    pl.col('prefarea').apply(binary_2_numeric)
)
```

shape: (545, 13)

price	area	bedrooms	bathrooms	stories	mainroad	guestroom	basement	hotwaterheating	airconditioning	parking	prefarea	furnishingstatus
i64	i64	i64	i64	i64	i64	i64	i64	i64	i64	i64	i64	str
13300000	7420	4	2	3	1	0	0	0	1	2	1	"furnished"
12250000	8960	4	4	4	1	0	0	0	1	3	0	"furnished"
12250000	9960	3	2	2	1	0	1	0	0	2	1	"semi-furnished…
12215000	7500	4	2	2	1	0	1	0	1	3	1	"furnished"
11410000	7420	4	1	2	1	1	1	0	1	2	0	"furnished"

Hình 41: Kết quả sau khi thực hiện hàm chuyển đổi giá trị "Yes"/"No" sang dạng số

Note: Các bạn đọc thêm về hàm `polars.DataFrame.apply()` tại đây.

- Hết -